

Resumen ejecutivo

1C Company es una de las firmas de software más grandes de Rusia, la cual opera una cadena de tiendas retail distribuidas en múltiples ciudades. El principal problema se encuentra en la planificación de inventarios, según cifras internas:

- 23% del inventario está en sobrestock
- 18% del tiempo hay quiebres de stock en productos clave
- Se ajustan inventarios cada 14 días, mientras la competencia lo hace en 48 horas
- Se han tenido pérdidas de \$6.8M USD en ventas

Así, el objetivo del proyecto es generar un modelo de Machine Learning que prediga la demanda mensual a nivel tienda-ítem, utilizando los datos otorgados por la empresa. Se espera que el modelo reduzca el error de predicción de RMSE ~ 11 unidades a menos de 5 unidades para alcanzar el margen operativo del 8.5%.

Los datos utilizados contienen ventas diarias por tienda-ítem de 2013 a 2015 de 60 tiendas y 22,169 ítems. Estos se agruparon los datos a nivel tienda-ítem-mes y se descartaron aquellas combinaciones que no hubieran presentado al menos una venta en todo el horizonte temporal estudiado. Bajo el supuesto de que si en 3 años no hubo ventas ni un solo mes, probablemente tampoco las habrá en un futuro.

Ahora bien, la lógica del modelo consiste en suponer que lo que se vende en el pasado, me da información útil para saber cuánto se venderá en el futuro. Siguiendo esa lógica, los predictores son las ventas rezagadas un mes (información más reciente), tres meses (tendencia trimestral), seis meses (tendencia semestral) y un año (tendencia anual). Dado que los datos se mantienen a nivel tienda-ítem-mes, no es necesario incluir sus identificadores.

Para probar el supuesto del impacto de la información pasada, se realizó un modelo base donde se indica que la predicción del mes de interés, será exactamente igual a la cantidad vendida el mes anterior (por tienda-ítem). De aquí se realizaron dos ejercicios, el primero fue usar la cantidad del mes anterior (panel balanceado) y el segundo fue utilizar la cantidad del mes previo disponible (panel desbalanceado). Posteriormente se comparó con los siguientes modelos de machine learning:

- Modelo Ridge (predictor: ventas un mes rezagado)
- Modelo Ridge (predictores: ventas uno y tres meses rezagados)
- Modelo Ridge (predictores: ventas uno, tres y seis meses rezagados)
- Modelo Ridge (predictores: ventas uno, tres, seis y doce meses rezagados)
- Modelo Random Forest (predictor: ventas un mes rezagado)
- Modelo Random Forest (predictores: ventas uno y tres meses rezagados)
- Modelo Random Forest (predictores: ventas uno, tres y seis meses rezagados)
- Modelo Random Forest (predictores: ventas uno, tres, seis y doce meses rezagados)

La métrica principal para evaluar y comparar los modelos fue el error cuadrático medio (RSME) debido a que esta métrica indica la diferencia entre los valores estimados y los valores reales. Cabe recordar que dentro de los objetivos del proyecto, se pedía una reducción a menos de 5 unidades.

La Tabla 1 presenta una comparación ejecutiva entre el método actual de pronóstico y los principales modelos de Machine Learning evaluados. Para cada modelo se reporta el RMSE, la mejora relativa frente al método actual, el porcentaje de predicciones que caen dentro de un rango operativo de ± 5 unidades, y el sesgo promedio de la predicción.

Como se observa, tanto el modelo **Ridge** como el **Random Forest** superan ampliamente al método actual, reduciendo el error de predicción en aproximadamente 15% y manteniendo

una alta confiabilidad operativa, con más del 99% de las predicciones dentro de ± 5 unidades y un sesgo prácticamente nulo.

De entre los modelos evaluados, el **Random Forest con rezagos de 1, 3, 6 y 12 meses** presenta el mejor desempeño global, alcanzando un **RMSE de 0.70 unidades**, lo que no solo cumple, sino que excede el objetivo operativo planteado. En consecuencia, este modelo fue seleccionado como la alternativa recomendada para su implementación.

MODELO	RMSE	MEJORA VS MÉTODO ACTUAL	% DENTRO +- 5USD	SESGO
Método Actual (lag 1)	0.83	---	99.6 %	Bajo
Ridge	0.71	+15%	99.7 %	Muy bajo
Random Forest	0.70	+15.5%	99.7 %	Muy bajo

Tabla 1. Modelos de Machine Learning evaluados

El detalle completo de las configuraciones evaluadas, incluyendo distintas combinaciones de rezagos y variantes del modelo base, se presenta en el Anexo 1, con el objetivo de documentar el proceso de selección.

Fortalezas

- El fuerte del modelo está en los productos y tiendas que tienen un historial consistente de ventas y patrones estacionales claros, lo que lo hace bastante útil para pronósticos de corto plazo.
- El uso del Random Forest permite modelar interacciones complejas entre los rezagos, lo que mejora la capacidad predictiva comparado con un modelo lineal.

Debilidades

- Se aplicó clipping tanto a las ventas históricas como a las predicciones a un rango plausible de 0 a 17 unidades (utilizando el percentil 99). Esto para obtener resultados más estables y alineados con el comportamiento general de la base (considerando que de todas las combinaciones de ítem-tienda, el 32.42% vendieron al menos 1 vez y que considerando las ventas mensuales el 75% de los datos tiene valores menores a 2). Parte del riesgo real está fuera del rango clip, por lo que habrá que ser precavido con ciertas SKUs con alta volatilidad siendo más precavido con las predicciones obtenidas y entendiendo que probablemente necesitan un análisis independiente o secundario.
- El análisis de RMSE por tienda muestra que el desempeño del modelo no es homogéneo entre todas las sucursales, lo cual es esperable por el tipo de enfoque de negocio (retail) con diferencia en demanda local y operativa. El modelo presenta una muy buena precisión en la mayoría de las tiendas. Sin embargo, como se puede visualizar en la Figura 2, existe un grupo pequeño de tiendas con mayor RMSE que requiere de más atención con implementaciones especiales para evitar posibles conflictos en la operación.




Figura 2. RMSE por tienda (tiendas donde el modelo es menos confiable)

Limitaciones

- El uso único de variables rezagadas limita que el desempeño del modelo se vea limitado en ítems o tiendas con poco historial de ventas o productos nuevos.
- El modelo no incorpora otro tipo de variables externas que podrían ser relevantes como el precio del ítem.
- El modelo puede subestimar la demanda donde el comportamiento analizado no refleja estrategias comerciales recientes.

El modelo Random Forest presenta un buen desempeño en la mayoría de las combinaciones tienda–ítem, lo cual se refleja en un RMSE promedio de 0.70 unidades y en que más del 99% de las predicciones se encuentran dentro de un rango de ± 5 unidades. El modelo es particularmente efectivo en tiendas con patrones de demanda estables, donde el RMSE es cercano a cero, así como en productos con un historial de ventas consistente, para los cuales los rezagos de 1, 3, 6 y 12 meses capturan adecuadamente la dinámica de la demanda.

No obstante, el análisis también identifica escenarios en los que el modelo requiere controles adicionales. En particular, se observan tiendas con alta volatilidad de demanda, caracterizadas por valores elevados de RMSE, así como combinaciones tienda–ítem con mayor riesgo, donde el error absoluto es superior al promedio. Adicionalmente, el desempeño del modelo es más limitado en productos con poca antigüedad o baja rotación, ya que un historial de ventas reducido disminuye la capacidad predictiva basada en variables rezagadas.

Recomendaciones accionables para operaciones y próximos pasos

El alto nivel de precisión del modelo permite automatizar el pronóstico en la mayoría de las tiendas y productos, mejorando la eficiencia del proceso de planeación de inventarios. Sin embargo, dado que el riesgo se concentra en un número reducido de combinaciones tienda–ítem, se recomienda aplicar controles específicos en escenarios de alta volatilidad.

Desde la perspectiva de innovación, el modelo demuestra el valor de aprovechar datos históricos para automatizar decisiones rutinarias y avanzar hacia una operación más data-driven. Como siguientes pasos, se sugiere incorporar criterios económicos que penalizan de forma diferenciada los quiebres de stock y establecer un monitoreo continuo del desempeño del modelo en operación.

